

O2 文档解析 Provider / Artifact 验收样例

用途：验证 /document/parse 的 provider metadata。

重点检查 PAGE_IMAGE、LAYOUT_JSON、TABLE block 和 IMAGE block。

本页包含普通文本层和规则表格。解析失败不应回退到 Tika 或纯文本链路。

一、设备巡检结果表

检查项	期望值	实际值	结论
网关在线率	>= 99.5%	99.8%	通过
采集延迟	<= 200ms	126ms	通过
异常告警数	<= 3	1	通过

验收要点：TABLE block 应带 pageNo、bboxJson、tableRows 和 tableHtml；同时生成 LAYOUT_JSON 与 PAGE_IMAGE artifact。

二、内嵌业务图片区域

下方图片用于验证 PDF raw image 是否进入 IMAGE block，并带 page、bbox 和图片对象。图片来自需要的例子演示/秒杀优惠券.png。




图 1：秒杀优惠券链路示意图，用于 IMAGE block、page/bbox 和图片 artifact 验收。

三、双栏 Reading Order 观察页

本页用于后续 O2.4 检查多栏阅读顺序。当前 PyMuPDF 轻量实现通常按 y0/x0 排序，可能产生左右栏交错。

左栏：数据进入链路

左栏 A1：采集任务先由边缘网关接收。

左栏 A2：网关完成协议适配、字段归一和时间戳校正。

左栏

A3：清洗后的数据写入消息队列，等待 RAG Tools 解析。

左栏

A4：解析结果应保持章节顺序，并记录 page 与 bbox。

左栏 A5：如果出现扫描页，后续 OCR provider 应生成 OCR_JSON。

右栏：观测与验收链路

右栏

B1：运维人员在控制台查看解析任务。

右栏 B2：任务详情展示

providerName、elapsedMs 和 warnings。

右栏 B3：PAGE_IMAGE

可用于管理端叠加 bbox 覆盖层。

右栏 B4：TABLE block 应继续进入 Java 表格结构化入库。

右栏 B5：IMAGE block 后续可接 VLM 生成语义 caption。